

Pipeline automatisé d'extraction sémantique

Objectif et vue d'ensemble

Ce pipeline automatise la partie du projet faite manuellement sur 9 items de questionnaires (PHQ-9, GAD-7, Epworth Sleepiness Scale) : relier chaque item à un concept SNOMED CT, juger la qualité de la correspondance (Exact / Broader / Narrower / No Match), puis générer un fragment RDF/Turtle.

Le pipeline enchaîne quatre étapes, chacune dans son propre script, avec un fichier de sortie distinct entre chaque étape :

- 1. **extraction_qwen_automatisee.py** — un LLM local (Qwen2.5-7B-Instruct, via Ollama) propose un concept clinique pour chaque item.
- 2. **recherche_snomed_B2.py** — l'API de recherche BioPortal renvoie des concepts SNOMED CT réels candidats pour ce terme.
- 3. **decision_match_C2.py** — le LLM choisit, parmi cette liste fermée de candidats, celui qui correspond le mieux (ou répond No Match).
- 4. **generation_ttl_D2.py** — un script génère automatiquement le fragment RDF/Turtle à partir de cette décision.

Le but est de faire la comparaison d'un résultat automatique, pour mesurer ce qu'un LLM apporte réellement par rapport à une recherche terminologique classique).

Les 9 items traités

Questionnaire	Items	Pourquoi ce choix
PHQ-9	phq2, phq4, phq7, phq9	humeur, symptôme somatique, cognition, item de sécurité (idéation suicidaire)
GAD-7	gad1, gad4, gad6	anxiété générale, manifestation psychophysiologique, irritabilité
Epworth Sleepiness Scale	epw4, epw8	deux situations à charge d'alerte différente (passager passif vs arrêt en circulation)

Les items ont été choisis pour couvrir des catégories sémantiques variées plutôt que de ne tester le pipeline que sur des symptômes affectifs.

Rôle de chaque fichier

Fichier	Rôle	Entrée	Sortie
<code>extraction_qwen_automatisee.py</code> (A2)	Demande au LLM un concept clinique par item	les 9 items (codés dans le script)	<code>resultats_A2.json</code> / <code>.csv</code>
<code>recherche_snomed_B2.py</code> (B2)	Interroge l'API BioPortal pour trouver des concepts SNOMED réels	<code>resultats_A2.json</code>	<code>resultats_B2_candidats.csv</code>
<code>decision_match_C2.py</code> (C2)	Demande au LLM de choisir un candidat ou No Match	<code>resultats_A2.json</code> + <code>resultats_B2_candidats.csv</code>	<code>resultats_C2_match.csv</code>
<code>generation_ttl_D2.py</code> (D2)	Construit le fragment RDF/Turtle à partir de la décision	<code>resultats_A2.json</code> + <code>resultats_C2_match.csv</code>	<code>questionnaire_ontology_AUTO_D2.ttl</code>
<code>valider_ttl_D2.py</code>	Vérifie la syntaxe du <code>.ttl</code> et la cohérence des <code>owl:sameAs</code>	le <code>.ttl</code> + <code>resultats_C2_match.csv</code>	un rapport affiché en console

Aucun des scripts n'a le droit d'inventer une valeur SNOMED : B2 ne retient que des identifiants renvoyés tels quels par l'API.

Nombre de candidats SNOMED recherchés

B2 demande 10 candidats par concept à l'API BioPortal (`PAGESIZE = 10`).

Ce choix est un compromis observé empiriquement : avec 5 résultats, le bon concept manquait parfois dans la liste (cas de *Depressed mood* ou *Suicidal thoughts*, absents du top 5 pour les termes recherchés). Avec 10, le bon concept apparaît plus souvent, mais la liste plus longue a aussi introduit de nouvelles erreurs : sur un item, le LLM a choisi à tort un concept de type trouble (*Mild depression*) apparu seulement grâce à l'élargissement. Élargir la liste de candidats améliore donc le rappel mais n'améliore pas automatiquement la précision du choix final.

Consignes données au prompt de décision du match (C2)

Le LLM reçoit l'item et la liste fermée des candidats renvoyés par B2 (identifiant, label préféré, définition, synonymes), et doit choisir le meilleur candidat ou répondre No Match, avec une justification courte.

Définitions imposées dans le prompt :

- **Exact** : le candidat et le construit de l'item ont la même portée.
- **Broader** : le candidat porte sur le même construit clinique mais de façon plus générale.
- **Narrower** : le candidat porte sur le même construit clinique mais de façon plus spécifique.
- **No Match** : aucun candidat ne porte sur le même construit clinique (domaine clinique différent).

Une règle de priorité précise que, dès qu'un candidat touche au même construit, même partiellement, il faut choisir Exact/Broader/Narrower — No Match est réservé aux cas de domaine clinique totalement différent. Une seconde règle précise que le "construit" ne couvre que le contenu clinique, pas le format de réponse (fréquence, situation) : un candidat ne doit jamais être rejeté simplement parce qu'il ne reprend pas l'échelle ou le contexte situationnel de l'item.

Trois garde-fous anti-hallucination sont appliqués par le SCRIPT, pas seulement par le prompt : un identifiant retourné qui n'appartient pas à la liste de candidats force automatiquement No Match ; un item sans aucun candidat est déclaré No Match sans même appeler le LLM ; le label final retenu vient toujours de B2, jamais de ce que le LLM a écrit.

Résultats obtenus

Item	Concept manuel	Match manuel	Concept automatique	Match automatique	Accord
phq2	Depressed mood	Narrower	Mild depression	Narrower	Concept différent
phq4	Fatigue	Exact	Fatigue	Exact	Accord total
phq7	Poor concentration	Exact	ADHD, combined type	Narrower	Concept différent (diagnostic inféré)
phq9	Suicidal thoughts	Narrower	Suicidal thoughts	Exact	Même concept, match plus sévère en manuel
gad1	Anxiety	Narrower	Anxiety	Exact	Même concept, match plus sévère en manuel
gad4	Aucun	No Match	Aucun	No Match	Accord total

Item	Concept manuel	Match manuel	Concept automatique	Match automatique	Accord
gad6	Feeling irritable	Exact	Feeling irritable	Exact	Accord total
epw4	Excessive daytime sleepiness	Narrower	Aucun	No Match	Faux négatif
epw8	Excessive daytime sleepiness	Narrower	Aucun	No Match	Faux négatif

Sur les 9 items : 3 accords totaux, 2 accords partiels (même concept, sévérité jugée différemment), 2 désaccords sur le concept retenu, 2 faux négatifs.

Limites connues

- **Erreurs qui persistent malgré des corrections de prompt explicites.** Sur epw4/epw8, le bon candidat (*Excessive daytime sleepiness*) était présenté en première position et a quand même été rejeté, même après l'ajout d'une règle dédiée dans le prompt C2. Le modèle 7B ne suit pas toujours une instruction nuancée de façon fiable.
- **B2 dépend entièrement de la qualité du terme proposé par A2.** B2 ne cherche que le mot que le LLM a lui-même produit en A2 ; si ce terme est imprécis ("depression" au lieu de "depressed mood", "attention_deficit" au lieu de "poor concentration"), le bon concept SNOMED n'apparaît parfois jamais dans les candidats proposés à C2, quelle que soit la qualité du prompt C2 ensuite.
- **Élargir la liste de candidats peut introduire de nouvelles erreurs.** Le passage de 5 à 10 candidats a permis de retrouver certains concepts manquants, mais a aussi fait apparaître un choix erroné (concept de type trouble) qui n'existait pas avec une liste plus courte.
- **Les items composites restent un problème structurel.** Quand un item cumule plusieurs notions ("A, B, or C"), le pipeline automatique tend à être moins prudent que la validation manuelle sur le choix entre Exact et Narrower.