



Documentation

🕒 Date de création	21 septembre 2026 13:51
📁 Matière	internship

Objectif du projet

Construire un pipeline semi-automatique permettant de relier des items de questionnaires cliniques (**PHQ-9**, **GAD-7** et **Epworth**) à des concepts **SNOMED CT**, puis de représenter ces correspondances dans une ontologie **RDF/OWL**.

Vue d'ensemble du pipeline

Item de questionnaire → Extraction par Qwen → Recherche dans SNOMED CT → Validation manuelle → Génération RDF/OWL

Étape	Entrée	Traitement	Sortie
1. Préparation	Dataset des questionnaires	Sélection des items	8 items cliniques
2. Extraction	Texte des items	Analyse avec Qwen2.5-7B-Instruct	Concepts candidats en JSON/CSV
3. Alignement	Concepts proposés	Recherche dans BioPortal	Concepts SNOMED CT candidats
4. Validation	Concepts candidats	Vérification sémantique manuelle	Match Exact, Narrower ou Broader
5. Modélisation	Correspondances validées	Construction avec RDF/OWL	Fragment d'ontologie en Turtle

1. Environnement et données

Environnement technique

- **LLM** : qwen2.5:7b-instruct
- **Exécution locale** : Ollama
- **Langage** : Python
- **Technologies sémantiques** : RDF, OWL et rdflib
- **Terminologie clinique** : SNOMED CT, consultée via BioPortal

Jeu de données

Le dataset contient les réponses de **776 étudiants en médecine au Mexique**. Il comprend notamment les colonnes suivantes :

- phq1 à phq9 pour le **PHQ-9** ;
- gad1 à gad7 pour le **GAD-7** ;
- epw1 à epw8 pour l'échelle de somnolence d'**Epworth**.

Pour cette première expérimentation, **8 items** ont été sélectionnés :

- 3 items du PHQ-9 ;
- 3 items du GAD-7 ;
- 2 items de l'échelle d'Epworth.

Choix du questionnaire:

L'ordre et la formulation exacte des 3 items PHQ-9 sélectionnés ont été confirmés par le manuel d'instructions officiel du PHQ qui reproduit l'intégralité des 9 items dans leur ordre standard . Pour les items GAD-7 et Epworth, cette

correspondance reste basée sur la standardisation reconnue de ces échelles, aucune source équivalente détaillant l'ordre exact des items n'ayant été consultée à ce stade.

2. Extraction des concepts avec Qwen

Le script `extraction_qwen.py` transmet chaque item sélectionné au modèle Qwen. Pour chaque item, le modèle doit produire une sortie structurée comprenant :

- le **concept clinique** principal ;
- la **catégorie** du concept ;
- la **relation sémantique** proposée ;
- un élément de **justification** (`evidence`).

Les résultats bruts sont enregistrés dans le fichier `resultats_extraction.csv`.

Exemple de sortie attendue

```
{
  "concept": "sleep disturbance",
  "category": "clinical finding",
  "relation": "assesses",
  "evidence": "The item evaluates difficulty related to sleep."
}
```

3. Alignement et validation avec SNOMED CT

Méthode de recherche

1. Rechercher dans BioPortal le terme proposé par Qwen.
2. Examiner le type et la définition du concept SNOMED CT trouvé.
3. Si le résultat correspond à un **trouble diagnostiqué** (*disorder*), rechercher un concept de type **constat clinique** (*finding*) plus adapté au niveau d'un item de questionnaire.

Car un item de questionnaire mesure un symptôme ponctuel, pas un diagnostic — le manuel du PHQ-9 le confirme, puisqu'il faut combiner plusieurs items et un jugement clinique pour diagnostiquer. J'ai donc privilégié le concept 'finding' (constat clinique) plutôt que 'disorder' (diagnostic), pour rester fidèle à ce que l'item mesure vraiment, sans sur-interpréter.

1. Comparer le sens de l'item, le concept proposé par Qwen et le concept SNOMED CT.

Tableau de validation complet

Item	Concept proposé par Qwen	Concept SNOMED CT retenu	Match	Validation sémantique	Correction manuelle	Pourquoi
phq1	Depression	Anhedonia	Narrower	Correct	Oui	1er résultat "Depressive disorder" trop générique/diagnostique → affiné vers "Anhedonia" (finding)
phq3	Sleep disturbance	Sleep pattern disturbance	Exact	Correct	Oui	1er résultat "Dyssomnia" (disorder) rejeté → affiné vers "Sleep pattern disturbance" (finding)
phq9	Suicidal ideation	Suicidal thoughts	Exact	Correct	Non	Correspondance directe dès la première recherche

Item	Concept proposé par Qwen	Concept SNOMED CT retenu	Match	Validation sémantique	Correction manuelle	Pourquoi
gad1	Anxiety	Anxiety	Exact	Correct	Non	Synonyme officiel "Feeling anxious" quasi identique au texte de l'item
gad3	Anxiety	Anxiety	Broader	Uncertain	Non	Aucun concept plus spécifique trouvé pour "excessive worry"
gad7	Anxiety	Anxiety	Broader	Uncertain	Non	Aucun concept plus spécifique trouvé pour "fear of disaster"
epw1	Sleepiness	Drowsy	Exact	Correct	Oui	"Excessive somnolence" écarté (trop interprétatif) au profit de "Drowsy", synonyme exact du mot de Qwen
epw4	Sleepiness	Drowsy	Exact	Correct	Oui	Même raisonnement que epw1

4. Critères de correspondance

Type de match	Définition	Exemple
Exact	Le concept SNOMED CT exprime le même sens que le concept extrait.	<i>Sleep disturbance</i> ↔ <i>Sleep pattern disturbance</i>
Narrower	Le concept SNOMED CT est plus précis que le concept proposé par le LLM.	<i>Anhedonia</i> est plus spécifique que <i>Depression</i> .
Broader	Le concept SNOMED CT est plus général que la nuance exprimée par l'item.	<i>Anxiety</i> est plus général que <i>excessive worry</i> .
No Match	Aucun concept suffisamment pertinent n'a été trouvé.	Aucun cas parmi les 8 items étudiés.

5. Construction du fragment d'ontologie

Le résultat final est enregistré dans `questionnaire_ontology.ttl`.

Modèle conceptuel

```

Questionnaire
├── hasItem → QuestionnaireItem
│   ├── assesses → ClinicalConcept
│   └── hasResponseScale → ResponseScale

```

Principes de modélisation

- Chaque item est relié au concept clinique qu'il évalue avec la relation `assesses`.
- Les concepts cliniques sont créés comme des **entités locales** dans l'ontologie.
- Une correspondance **Exact** est reliée à SNOMED CT avec `owl:sameAs`.
- Une correspondance **Broader** ou **Narrower** est documentée avec `rdfs:seeAlso` afin de ne pas affirmer une équivalence stricte.

L'ontologie sépare clairement 4 types d'entités : le questionnaire, ses items, les concepts cliniques qu'ils évaluent, et les échelles de réponse. Chaque item est relié à son concept par 'assesses'. Les concepts sont des entités que j'ai créées moi-même, reliées à SNOMED CT soit par owl:sameAs quand la correspondance est exacte, soit par rdfs:seeAlso quand elle est seulement approximative — pour ne jamais affirmer une équivalence que je n'ai pas vérifiée à 100%.

6. Exemple complet du pipeline (item **phq3**)

Item de questionnaire : PHQ-9, **phq3** — *"Trouble falling or staying asleep, or sleeping too much"*

Extraction Qwen : concept = **sleep disturbance**, catégorie = **symptom**, relation = **measures**

Alignement SNOMED CT : recherche **sleep disturbance** → **Dyssomnia** (disorder, rejeté) → recherche affinée **sleep pattern disturbance** → **Sleep pattern disturbance** (**26677001**, finding, retenu) → Match = **Exact**

Triplets RDF générés :

```
:phq3 a :QuestionnaireItem ;
      :assesses :SleepPatternDisturbance ;
      :hasResponseScale :Scale0to3Frequency .

:SleepPatternDisturbance a :ClinicalConcept ;
      owl:sameAs snomed:26677001 .
```

Validation manuelle : RDF syntax = **Pass** · Validation sémantique = **Correct** · Correction manuelle = **Oui** (rejet du premier résultat trop générique)

7. Fichiers du projet

Fichier	Rôle
extraction_qwen.py	Extrait, pour chaque item, un concept, une catégorie, une relation et une justification.
resultats_extraction.csv	Contient les sorties brutes générées par Qwen pour les 8 items.
validation_table.csv	Regroupe les recherches SNOMED CT et les décisions de validation sémantique.
questionnaire_ontology.ttl	Contient le fragment final de l'ontologie au format Turtle.
validation_syntax_output.txt	Conserve la preuve de validation syntaxique du fichier Turtle.
exemple_complet_pipeline.md	Présente le pipeline complet appliqué à l'item phq3 .