

Extraction sémantique PHQ-9 / GAD-7 / Epworth vers SNOMED CT

Récapitulatif du travail — support pour la présentation

1. Objectif et méthode

Pipeline suivi : item de questionnaire → Qwen2.5-7B-Instruct (Ollama, en local) → recherche manuelle dans SNOMED CT → validation → fragment RDF/OWL/Turtle. Qwen ne connaît pas SNOMED CT et n'y a pas accès : il propose un concept en anglais médical, jamais un code. La vérification et le choix du match restent entièrement manuels.

2. Sélection des 9 items

Choisis pour couvrir des catégories sémantiques différentes, afin de ne pas tester Qwen uniquement sur des symptômes affectifs.

Instrument	Items	Pourquoi
PHQ-9	phq2, phq4, phq7, phq9	humeur, symptôme somatique, cognition, item de sécurité (idéation suicidaire)
GAD-7	gad1, gad4, gad6	anxiété générale, manifestation psychophysiologique, irritabilité
Epworth	epw4, epw8	deux situations à charge cognitive différente (passager passif vs. arrêt en circulation)

Un item Epworth (epw2) et un item d'origine ont été retirés en cours de route pour accélérer les lancements (passage de 10 à 9 items).

3. Évolution du prompt (le point clé de l'évaluation)

Version 1 (avant ce travail) : consigne trop générique, aucune contrainte de catégorie, aucune règle sur les diagnostics, aucun format imposé strictement.

Versions 2 et 3, améliorations successives :

- Catégories fermées (finding, symptom, disorder, behavior, observable_entity, assessment_scale) au lieu de labels libres.
- Interdiction explicite d'inventer un code SNOMED CT.
- Relation optionnelle et typée (predicate parmi une liste fermée, target_concept différent du concept).
- Règle « symptôme, pas trouble » : l'item doit être relié au symptôme qu'il mesure, pas à la maladie que dépiste le questionnaire.
- Règle spécifique à l'Epworth : la situation (voiture, télé) n'est qu'un test de la somnolence, pas le concept mesuré.
- Colonne evidence : d'abord une citation exacte de l'item (redondante avec Source), puis une justification en une phrase, sans recopier l'item ni citer un diagnostic absent.
- Status (existing_concept / candidate_project_concept) demandé dès la sortie Qwen, à confirmer après recherche.

Ce que ça a changé, concrètement : meilleure discipline de format (JSON valide, catégories respectées), nette amélioration sur l'Epworth (risk_of_sleeping_while_driving → daytime sleepiness). En revanche, plusieurs erreurs de fond ont persisté d'une version à l'autre : Qwen reste attiré par le niveau « trouble » plutôt que « symptôme » pour phq2, phq7 et gad4, et produit encore une relation qui redécrit le concept au lieu de le relier à l'item.

4. Résultats et corrections par item

Item	Concept proposé par Qwen	Concept validé	Correction nécessaire
phq2	depression	Depressed mood	Oui — Qwen visait le trouble, pas l'état d'humeur
phq4	fatigue	Fatigue	Non
phq7	attention_deficit	Poor concentration	Oui — dérive vers le TDAH, absent de l'item
phq9	suicidal ideation	Suicidal thoughts	Oui, sur la relation seulement (concept correct)
gad1	anxiety	Anxiety	Oui, sur la relation seulement (concept correct)
gad4	anxiety	aucun (Candidate Project Concept)	Oui — proposition redondante avec gad1
gad6	irritability	Feeling irritable	Oui, sur la relation seulement (concept correct)
epw4	risk_of_sleepiness → daytime sleepiness	Excessive daytime sleepiness	Non sur le concept final, label instable entre les runs
epw8	risk_of_sleeping_while_driving → daytime sleepiness	Excessive daytime sleepiness	Oui — première version trop spécifique (conduite)

5. Logique de choix du Match

Règle appliquée : **Exact seulement si le concept SNOMED couvre l'intégralité de ce que dit l'item.** Beaucoup d'items du PHQ-9/GAD-7 sont des disjonctions (« A, B, or C »), et le concept SNOMED ne couvre souvent qu'un des termes.

- **phq4 (Exact)** : « tired or little energy » — Fatigue couvre les deux facettes (synonyme Weariness).
- **phq7 (Exact)** : « trouble concentrating » — Poor concentration correspond exactement, sans ajout de diagnostic.
- **gad6 (Exact)** : « easily annoyed or irritable » — Feeling irritable couvre l'essentiel, léger écart mineur toléré.
- **phq2, gad1, phq9 (Narrower)** : items composites où un mot de l'item n'est pas couvert (« hopeless », « nervous »/« on edge », automutilation non-suicidaire).
- **epw4, epw8 (Narrower)** : Excessive daytime sleepiness ajoute une notion de seuil clinique (« excessive ») que l'item ne présuppose pas, puisqu'il mesure une probabilité graduée de 0 à 3.
- **gad4 (No Match)** : aucun concept SNOMED trouvé pour « trouble relaxing », malgré plusieurs formulations essayées → Candidate Project Concept.

Concepts candidats explorés puis rejetés (à mentionner en présentation, montre le travail de recherche) : Attention deficit hyperactivity disorder suspected (situation de suspicion diagnostique), Feeling nervous (trop étroit face à gad1), Lack of energy (trop étroit face à phq4), Drowsy (état sans dimension diurne) et Hypersomnia (un trouble, pas un symptôme) pour les items Epworth.

6. Structure RDF/Turtle

Respecte le modèle imposé : Questionnaire —hasItem→ QuestionnaireItem —assesses→ ClinicalConcept, avec hasResponseScale séparé. Chaque item, concept et échelle est une entité distincte (pas de fusion item/concept).

Règle appliquée sur owl:sameAs : utilisé uniquement pour les 3 matches Exact (Fatigue, Poor concentration, Feeling irritable). Pour les Narrower et le No Match, le concept clinique existe dans le graphe (avec un commentaire explicatif) mais sans lien d'équivalence vers SNOMED : l'alignement approché reste consigné uniquement dans le tableau de mapping, jamais affirmé comme équivalence dans le RDF.

7. Validation

- **Syntaxique** : le fichier est chargé avec rdflib (Graph().parse(..., format="turtle")) → aucune erreur, 138 triplets.
- **Sémantique**, contrôlée automatiquement puis relue à la main : chaque item a exactement un questionnaire, un concept, une échelle ; aucun item n'est aussi typé comme concept clinique ; owl:sameAs n'apparaît que sur les 3 concepts Exact prévus ; aucune URI SNOMED inventée (liste fermée des identifiants vérifiés).

8. Limites à assumer en présentation

- Le modèle 7B tend à remonter au diagnostic plutôt qu'au symptôme, malgré une règle explicite pour l'en empêcher.
- Les items composites (« A, B, or C ») posent structurellement un problème d'équivalence : aucune version du prompt n'a résolu ça, c'est une limite de la correspondance un-item/un-concept elle-même.
- Excessive daytime sleepiness reste un compromis : son parent plus neutre (Daytime somnolence, mentionné dans sa fiche SNOMED) n'a pas été retrouvé dans la recherche.
- gad4 illustre un vrai trou terminologique dans SNOMED CT pour un item très utilisé cliniquement.